ENSAE

MS Actuariat — Generative AI for Insurance and Actuarial Studies

Génération de cartes climatiques par modèles génératifs profonds
Application à la température dans le Sud-Est de la France

Killian Chevrier Arthur Georgi Elric Roussel

Année universitaire 2025-2026

Table des matières

Introduction **2**

1 Importation et traitement des données **2**
1.1 Création des cartes de températures . . . 2
1.2 Enrichissement des données et préparation pour l'entraînement . . . 3

2 Analyse descriptive **3**

3 Modèles statistiques de référence **3**
3.1 Modèle gaussien multivarié conditionnel . . . 3
3.2 Modèle KDE-PCA conditionnel . . . 4

4 Auto-Encodeur Variationnel Conditionnel (CVAE) **4**
4.1 Principe du VAE . . . 4
4.2 Conditionnement via la modulation FiLM . . . 4
4.3 Espace latent ($d_z = 32$) . . . 4
4.4 Fonction de perte et entraînement . . . 5
4.5 Génération conditionnelle . . . 5

5 Réseau Antagoniste Génératif conditionnel (cWGAN-GP) **5**
5.1 Principe du GAN et du WGAN-GP . . . 5
5.2 Architecture du générateur . . . 6
5.3 Architecture du critique (discriminateur) . . . 6
5.4 Entraînement . . . 6

6 Évaluation et comparaison des modèles **6**
6.1 Évaluation isolée du CVAE : Métriques de reconstruction et validation visuelle . . . 6
6.2 Comparaison des modèles . . . 7

Conclusion **7**

Annexes **9**

Introduction

Le changement climatique place les assureurs face à un défi de modélisation inédit : les produits d'assurance climatique requièrent une connaissance fine de la distribution des aléas, y compris dans leurs queues, alors que les données historiques sont naturellement rares. Pour modéliser efficacement les aléas climatiques et leur queue de distribution, il est nécessaire de lutter contre la contrainte de volume des données en enrichissant les bases de données historiques. Les réseaux de neurones génératifs offrent une voie prometteuse pour répondre à cette problématique en produisant des scénarios plausibles au-delà de l'historique disponible, grâce à la flexibilité de leur architecture et à leur adaptabilité.

Ce projet explore donc la génération de **cartes spatiales de température mensuelle** à l'aide de deux réseaux de neurones génératifs : un réseau de la famille des auto-encodeurs variationnels (VAE) et un réseau de la famille des réseaux antagonistes génératifs (GAN). Nous commençons par présenter les données utilisées et le périmètre étudié. Ensuite, nous présentons les deux réseaux utilisés ainsi que deux modèles de comparaison qui permettront d'évaluer leur performance. Enfin, nous comparons les résultats des modèles avant de conclure cette étude.

1 Importation et traitement des données

1.1 Création des cartes de températures

Pour réaliser cette étude, nous avons utilisé des données climatiques mensuelles obtenues à l'aide du modèle SAFRAN-SIM de Météo-France, qui produit des champs météorologiques sur une grille régulière de 8 km × 8 km couvrant la France métropolitaine. Ces données mensuelles sont disponibles d'août 1958 à mars 2026, pour un total de 812 cartes, un faible total pour entraîner des modèles génératifs.

Pour faire face à cette contrainte de volume de données, nous avons décidé d'étudier la **température moyenne**, une variable dont les variations sont plus régulières et lisses que celles d'autres variables comme les précipitations ou l'humidité des sols. La simplicité de cette variable rend alors l'apprentissage de ses subtilités plus facile avec un nombre de données réduit.

De plus, nous avons réduit la taille des cartes à générer en limitant notre étude au **Sud-Est de la France**. Cette zone présente l'intérêt d'un fort contraste altitudinal, avec trois zones distinctes : le Massif Central à l'ouest, la vallée du Rhône au centre et les Alpes à l'est. Ce contraste est reflété sur les cartes de températures de la zone, avec une dynamique spatiale identifiable :

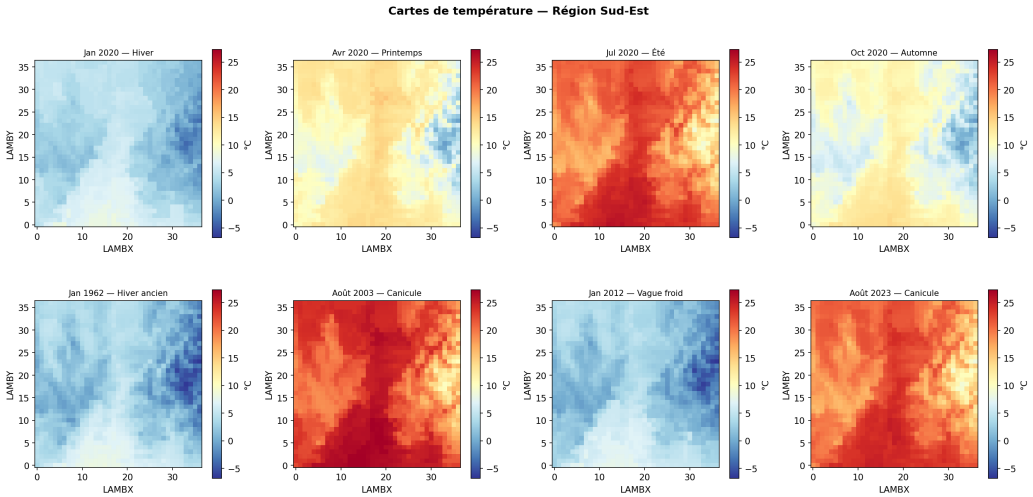

Figure 1 – Exemples de cartes de températures sur la zone Sud-Est

Pour constituer les cartes de températures, nous avons filtré les points de température sur la base des coordonnées x et y (`LAMBX` et `LAMBY`) pour isoler la zone Sud-Est. Ensuite, nous avons concaténé les points

en fonction de leurs coordonnées pour créer des matrices. Nous obtenons ainsi un jeu de données de forme $(N, H, W) = (812, 37, 37)$ où N est le nombre de pas de temps et $H \times W$ est la résolution spatiale. Chaque carte est donc une matrice 37×37 de températures en °C.

1.2 Enrichissement des données et préparation pour l'entraînement

Dans ce projet, nous avons choisi d'étudier des architectures conditionnelles afin de générer des images correspondant à des dates précises. Nous avons donc enrichi la base de données en construisant, pour chaque carte, un vecteur de conditionnement contenant trois variables de temps :

$$\mathbf{c} = \left(\cos(\tfrac{2\pi(m-1)}{12});\ \sin(\tfrac{2\pi(m-1)}{12});\ \tfrac{year - year_{\min}}{year_{\max} - year_{\min}}\right), \tag{1}$$

où $m \in \{1, \ldots, 12\}$ est le mois et $year$ l'année. La représentation circulaire du mois (cosinus/sinus) évite la discontinuité entre décembre et janvier en permettant un encodage continu et périodique de la saisonnalité. La variable d'année normalisée capture la tendance de réchauffement à long terme.

La base est ensuite découpée en ensembles d'entraînement (80%) et de test (20%) en stratifiant par année pour préserver la représentation de chaque période. L'ensemble d'entraînement est ensuite lui-même subdivisé en train (90%) et validation (10%) lors de l'optimisation des modèles. Enfin, les cartes sont standardisées par Z-score, avec la moyenne μ_{train} et l'écart-type σ_{train} calculés sur le jeu d'entraînement uniquement afin d'éviter toute fuite d'information.

2 Analyse descriptive

La distribution globale de la température sur l'ensemble des pixels et des pas de temps révèle une **bimodalité** prononcée, illustrant le contraste entre les mois d'hiver et d'été (Figure 4). Cette forte non-stationnarité rend caduque l'utilisation d'une modélisation statistique globale simple à l'aide d'une loi gaussienne.

En revanche, conditionnellement à une saison donnée, la distribution se rapproche d'une gaussienne, ce qui justifie l'utilisation de modèles conditionnels (Figure 5). Le cycle saisonnier se reflète dans les moyennes mensuelles, avec des moyennes allant de $1,43$ °C en janvier à $18,6$ °C en juillet-août (Figure 6). La tendance de réchauffement climatique est également hétérogène d'une saison à l'autre, avec un réchauffement par décennie de $0,45$ °C pour les mois d'été, contre $0,22$ °C pour les mois d'hiver (Figure 7).

En plus de la dynamique temporelle, les données suivent une structure spatiale précise (Figure 8). Comme observé dans les exemples de cartes, le relief divise le Sud-Est de la France en trois blocs distincts. De plus, la tendance de réchauffement est hétérogène sur le territoire, avec une bande de réchauffement fort et une zone de stabilité des températures.

3 Modèles statistiques de référence

Pour évaluer l'efficacité des réseaux de neurones génératifs construits dans cette étude, nous implémentons deux modèles statistiques de référence.

3.1 Modèle gaussien multivarié conditionnel

Ce modèle décompose la distribution des cartes en une composante *conditionnelle* (dépendant du vecteur $\mathbf{c}$) et une composante *résiduelle* :

$$\mathbf{x} = \boldsymbol{\mu}(\mathbf{c}) + \boldsymbol{\varepsilon}, \qquad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \hat{\Sigma}) \tag{2}$$

où $\mathbf{x} \in \mathbb{R}^{1369}$ est la carte aplatie, $\boldsymbol{\mu}(\mathbf{c}) = \mathbf{W}\mathbf{c} + \mathbf{b}$ est appris par régression Ridge (régularisation $\alpha = 1$), et $\hat{\Sigma}$ est la matrice de covariance empirique des résidus. Pour générer de nouvelles cartes, le modèle échantillonne $\boldsymbol{\varepsilon}$ selon la loi $\mathcal{N}(\mathbf{0}, \hat{\Sigma})$ et y ajoute l'espérance prédite à partir des variables de conditionnement. Ce modèle simple

permet de capturer la structure spatiale via $\hat{\Sigma}$ et la dynamique temporelle (cycle saisonnier et réchauffement) via la régression.

3.2 Modèle KDE-PCA conditionnel

Ce second modèle de référence repose sur la méthode des analogues. Les données d'entraînement sont d'abord projetées dans un espace latent via une analyse en composantes principales ($d = 64$). Pour générer une nouvelle carte conditionnée à un vecteur $\mathbf{c}$, un algorithme des k-plus-proches-voisins ($k = 50$) sélectionne d'abord les situations historiques les plus similaires. Une estimation par noyau (KDE gaussien, $h = 0{,}8$) est alors ajustée sur les représentations latentes de ce voisinage précis pour générer un nouveau tirage, lequel est finalement reconstruit en image par ACP inverse.

4 Auto-Encodeur Variationnel Conditionnel (CVAE)

4.1 Principe du VAE

Un Auto-Encodeur Variationnel (VAE) apprend conjointement un **encodeur** $q_\phi(\mathbf{z}|\mathbf{x})$ qui projette une observation $\mathbf{x}$ dans un espace latent de dimension d_z, et un **décodeur** $p_\theta(\mathbf{x}|\mathbf{z})$ qui reconstruit l'observation à partir d'un code latent $\mathbf{z}$. L'objectif du VAE la maximisation de la borne inférieure variationnelle (ELBO) :

$$\mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})]}_{\text{reconstruction}} - \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \,\|\, p(\mathbf{z}))}_{\text{régularisation}} \tag{3}$$

Le terme de reconstruction assure une reconstruction fidèle des images, tandis que le terme de régularisation contraint $q_\phi(\mathbf{z}|\mathbf{x})$ à rester proche de la distribution a priori $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. Contrairement à un auto-encodeur déterministe classique, dont l'espace latent est souvent fragmenté, cette pénalité force un lissage de l'espace latent. Ce lissage permet d'échantillonner de nouveaux points cohérents et d'interpoler de manière fluide entre différentes observations afin de générer de nouvelles données.

4.2 Conditionnement via la modulation FiLM

Pour intégrer les conditions temporelles $\mathbf{c}$ (Équation 1), le CVAE utilise la technique **FiLM** (*Feature-wise Linear Modulation*, Perez *et al.* 2017). Plutôt que de simplement concaténer la condition à l'entrée du réseau, FiLM utilise un sous-réseau dense pour transformer $\mathbf{c}$ en deux vecteurs de paramètres dynamiques : un facteur d'échelle $\boldsymbol{\gamma}$ et un décalage $\boldsymbol{\beta}$:

$$\text{FiLM}(\mathbf{h}, \mathbf{c}) = \boldsymbol{\gamma}(\mathbf{c}) \odot \mathbf{h} + \boldsymbol{\beta}(\mathbf{c}), \qquad \boldsymbol{\gamma}(\mathbf{c}) = \mathbf{1} + \Delta\boldsymbol{\gamma}(\mathbf{c}) \tag{4}$$

$\Delta\boldsymbol{\gamma}$ est initialisé à zéro, ce qui garantit que le réseau démarre comme un modèle non conditionné, favorisant ainsi la stabilité en début d'entraînement.

L'avantage de cette approche est la possibilité d'implémenter le vecteur de conditions à toutes les profondeurs de l'architecture convolutionnelle. En modulant les activations à chaque étape de l'architecture, la condition influence l'extraction des caractéristiques et la génération d'images à de multiples granularités. Aux résolutions spatiales les plus faibles (couches profondes, au cœur du réseau), FiLM pilote la structure sémantique globale (le macro-climat saisonnier). À l'inverse, aux résolutions spatiales élevées (couches périphériques, proches des images), la modulation affine le traitement des détails locaux précis. La structure précise de l'architecture du CVAE est détaillée en annexe, à la Figure 2.

4.3 Espace latent ($d_z = 32$)

Dans notre architecture de CVAE, la saisonnalité et la tendance sont intégrées via les couches FiLM. L'espace latent a donc pour unique rôle d'encoder la *variabilité météorologique résiduelle* non expliquée par la condition : anomalies locales, épisodes extrêmes ponctuels (canicule d'août 2003, vague de froid de janvier 2012). Ainsi, contrairement à un VAE standard où l'espace latent s'organise en clusters sémantiques distincts,

l'espace latent du CVAE doit être invariant vis-à-vis des conditions. La différenciation macroscopique est donc entièrement déléguée aux vecteurs de conditions.

La projection des quatre premières dimensions latentes (Figure 9) valide cette architecture : les points s'y répartissent uniformément sans former de regroupements par saison ou par année. Cette absence de clusters démontre que le signal temporel a bien été absorbé par le conditionnement FiLM et non mémorisé par l'espace latent. La dimension $d_z = 32$ a été choisie empiriquement car elle offre le meilleur compromis entre capacité de reconstruction et prévention du surapprentissage.

4.4 Fonction de perte et entraînement

La fonction de coût $\mathcal{L}_{\text{CVAE}}$ équilibre l'erreur de reconstruction et la régularisation de l'espace latent à l'aide du poids de régularisation β_t :

$$\mathcal{L}_{\text{CVAE}} = \underbrace{\frac{1}{N_{\text{px}}}\|\mathbf{x} - \hat{\mathbf{x}}\|_F^2}_{\text{MSE reconstr.}} + \beta_t \cdot \underbrace{\left(-\frac{1}{2d_z}\sum_{j=1}^{d_z}(1 + \log\sigma_j^2 - \mu_j^2 - \sigma_j^2)\right)}_{\text{KL-divergence}} \tag{5}$$

Pour éviter le phénomène d'effondrement latent (*posterior collapse*) en début d'apprentissage, nous appliquons une montée progressive de $\beta_t = 0$ à $\beta_t = 0{,}5$ durant les 50 premières époques. Par ailleurs, une désactivation aléatoire (*dropout* à 5%) est appliquée sur le vecteur latent $\mathbf{z}$ afin de forcer le décodeur à exploiter pleinement les conditions $\mathbf{c}$. L'optimisation est réalisée par l'algorithme Adam (taux d'apprentissage de 10^{-3}), couplé à un ordonnanceur *ReduceLROnPlateau* (facteur 0,5, patience 10) et un arrêt prématuré (*early stopping*, patience 50). Les hyperparamètres complets du CVAE sont détaillés dans le Tableau 3.

4.5 Génération conditionnelle

La synthèse d'une nouvelle carte météorologique pour une date cible $\mathbf{c}^*$ (mois m^*, année t^*) s'amorce par l'échantillonnage d'un vecteur latent $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, permettant l'injection de la variabilité stochastique, ou par l'assignation $\mathbf{z} = \mathbf{0}$ si l'objectif est de générer la carte climatique moyenne. Ce vecteur, couplé à la condition temporelle, traverse ensuite le décodeur pour créer une carte normalisée $\hat{\mathbf{x}} = \text{Decoder}_\theta(\mathbf{z}, \mathbf{c}^*)$. Enfin, une étape de destandardisation projette cette prédiction mathématique vers l'espace physique des températures réelles : $\hat{\mathbf{x}}_{^\circ\text{C}} = \hat{\mathbf{x}} \cdot \sigma_{\text{train}} + \mu_{\text{train}}$.

Grâce à cette méthode, le CVAE permet de générer des scénarios pour des dates spécifiques. De plus, il est possible de simuler des scénarios futurs, le réseau extrapolant alors la tendance de réchauffement encodée dans la composante `year_norm` du vecteur $\mathbf{c}^*$ (Figure 10).

5 Réseau Antagoniste Génératif conditionnel (cWGAN-GP)

5.1 Principe du GAN et du WGAN-GP

Un réseau antagoniste génératif (GAN) met en compétition un **générateur** G et un **discriminateur** D dans un jeu minimax :

$$\min_G \max_D \; \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}[\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z}\sim p_z}[\log(1 - D(G(\mathbf{z})))] \tag{6}$$

Pour pallier les instabilités de cet apprentissage (*mode collapse*, évanouissement du gradient), le WGAN (*Arjovsky et al., 2017*) remplace le discriminateur par un **critique** f à sorties non bornées, et minimise la distance de Wasserstein :

$$W(p_{\text{data}}, p_G) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}[f(\mathbf{x})] - \mathbb{E}_{\mathbf{z}\sim p_z}[f(G(\mathbf{z}))] \tag{7}$$

Le calcul exact de cette distance exige que f soit une fonction 1-Lipschitz ($\|f\|_L \leq 1$). Pour imposer cette contrainte de manière souple, l'algorithme WGAN-GP (*Gulrajani et al., 2017*) pénalise la norme du gradient

du critique (Gradient Penalty) :

$$\mathcal{L}_D = \underbrace{\mathbb{E}[f(\hat{\mathbf{x}})] - \mathbb{E}[f(\mathbf{x})]}_{\text{Approx. de Wasserstein}} + \lambda \underbrace{\mathbb{E}\Big[\big(\|\nabla_{\hat{\mathbf{x}}} f(\tilde{\mathbf{x}})\|_2 - 1\big)^2\Big]}_{\text{Pénalité de gradient}}, \tag{8}$$

où $\mathbf{x}$ est une image réelle, $\hat{\mathbf{x}} = G(\mathbf{z})$ est l'image générée, $\tilde{\mathbf{x}} = \alpha\mathbf{x} + (1-\alpha)\hat{\mathbf{x}}$ est une interpolation aléatoire entre les deux (avec $\alpha \sim \mathcal{U}[0,1]$), et λ est le coefficient de pénalité.

5.2 Architecture du générateur

Le générateur suit une architecture similaire à celle du décodeur CVAE (couches convolutionnelles transposées, conditionnement FiLM), avec l'ajout d'une concaténation avec le vecteur de conditions au début du réseau, d'une **Batch Normalization** à chaque étape et un passage de l'espace latent à la dimension 64 au lieu de 32. Cette architecture est détaillée en annexe à la Figure 3.

5.3 Architecture du critique (discriminateur)

Le critique adopte une architecture miroir de l'encodeur, en intégrant toutefois une **Instance Normalization**. Contrairement à la *Batch Normalization*, cette couche garantit l'indépendance des échantillons au sein du mini-batch vu par le critique. Cette condition est essentielle pour que le calcul de la *Gradient Penalty* reste mathématiquement valide.

De plus, le conditionnement du critique s'opère par **projection** plutôt que par couches FiLM. Ce choix asymétrique de méthodes de conditionnement est également dicté par le calcul de la pénalité de gradient. En effet, l'injection de modulations multiplicatives dynamiques au cœur du réseau via des couches FiLM rendrait le gradient de la sortie ($\nabla_{\hat{\mathbf{x}}} f$) instable. Un tel comportement ferait échouer la *Gradient Penalty* et le maintien de la contrainte 1-Lipschitz, tandis que la projection préserve la régularité du gradient nécessaire à l'estimation de la distance de Wasserstein. Le score global $S(\mathbf{x}, \mathbf{c})$ évalué par le critique se formule ainsi :

$$S(\mathbf{x}, \mathbf{c}) = D(\mathbf{x}) + \langle \varphi(\mathbf{x}), \mathbf{W}_c \mathbf{c} \rangle \tag{9}$$

où $\varphi(\mathbf{x}) \in \mathbb{R}^{1600}$ est la représentation aplatie après les convolutions, et $\mathbf{W}_c \in \mathbb{R}^{1600\times 3}$ est une couche de projection sans biais des conditions. Ce score de projection (*Miyato & Koyama, 2018*) permet ainsi au critique d'évaluer non seulement le réalisme de l'image, mais aussi sa cohérence avec la condition $\mathbf{c}$ (Figure 3).

5.4 Entraînement

L'entraînement suit le protocole standard du WGAN-GP. Le critique est mis à jour $N_{\text{critic}} = 5$ fois par itération du générateur. L'optimisation s'effectue via Adam ($lr = 10^{-4}$), en utilisant des moments asymétriques $\beta = (0, 0{,}9)$. L'annulation de l'inertie ($\beta_1 = 0$) est ici essentielle car elle empêche l'élan des gradients passés d'influencer l'optimisation dans le contexte particulier des GAN. L'ensemble des hyperparamètres est résumé dans le Tableau 5.

La Figure 11 nous permet d'observer les étapes d'apprentissage du cWGAN-GP. La première génération est un simple bruit, puis les cartes générées convergent au fil de l'apprentissage vers des cartes réalistes.

6 Évaluation et comparaison des modèles

6.1 Évaluation isolée du CVAE : Métriques de reconstruction et validation visuelle

Sur l'ensemble de test, le CVAE atteint des performances de reconstruction satisfaisantes, avec une RMSE d'environ 0,9 °C en utilisant μ_{enc} (mode déterministe). Cette erreur est spatialement homogène sur l'ensemble du territoire étudié. L'absence de structure géographique dans le biais démontre une bonne compréhension de la morphologie des champs de température par le réseau (Figure 12).

Nous évaluons également l'adaptabilité du CVAE à l'aide d'un balayage de conditions temporelles (Figure 13). Celui-ci révèle que, sans composante aléatoire, le réseau est capable de générer des cartes captant fidèlement la structure spatiale du territoire tout en incorporant la tendance et la saisonnalité des températures. En particulier, les différences de températures entre les cartes générées en 2050 et en 2026 correspondent à la tendance climatique, avec une structure spatiale réaliste et un réchauffement plus fort en été, ce qui montre que le réseau est capable d'extrapoler la tendance pour générer des scénarios futurs. La Figure 10 étend ce constat à la génération stochastique, avec des résultats cohérents pour des cartes aléatoires de juillet 2026 et de juillet 2050.

6.2 Comparaison des modèles

Une première évaluation visuelle (Figure 14) révèle des performances historiques similaires entre les réseaux de neurones et les modèles statistiques : tous capturent efficacement la dynamique saisonnière et la structure spatiale régionale. Cependant, l'extrapolation de scénarios futurs souligne de fortes disparités. En particulier, le KDE-PCA, limité par la méthode des analogues, échoue à simuler des températures inédites liées au réchauffement climatique.

Afin de compléter cette observation avec une analyse quantitative rigoureuse, nous générons un ensemble de 10 cartes pour chaque date de la base de données et pour chaque modèle. Ces données permettent de confronter les distributions spatiales via des diagrammes quantile-quantile (Q-Q plots) et des variogrammes, puis de calculer la *Sliced Wasserstein Distance* (SWD).

L'analyse des Q-Q plots (moyennes, 75e et 95e centiles, maxima) désigne le CVAE comme le modèle le plus fidèle (Figure 15). Ses distributions s'alignent presque parfaitement sur la réalité empirique. Le modèle gaussien le suit de près, malgré une légère sous-estimation globale. À l'inverse, le cWGAN-GP et surtout le KDE-PCA surestiment les maxima, avec des biais positifs respectifs d'environ 1 °C et 2 °C.

Nous évaluons ensuite la reproduction de la structure spatiale des cartes à l'aide de variogrammes (Figure 16). Par construction, le modèle gaussien s'aligne sur la référence empirique. Le CVAE se positionne légèrement en dessous, illustrant sa tendance à produire des prédictions légèrement plus lisses. À l'inverse, le cWGAN-GP surestime la variance spatiale, ce qui traduit l'injection d'un bruit de contraste par le générateur pour tromper le critique. Cette surestimation est encore plus prononcée pour le modèle KDE-PCA.

Enfin, la *Sliced Wasserstein Distance* (Figure 17) permet de quantifier l'écart global des distributions. Le CVAE s'impose comme le modèle le plus fidèle à la distribution réelle avec la SWD la plus faible (1,47), talonné par le cWGAN-GP (1,54). Les modèles statistiques sont ici moins performants : le modèle gaussien atteint 1,68, et le KDE-PCA 1,98. Ce classement complète les analyses précédentes en montrant que, bien qu'il bénéficie de la structure gaussienne conditionnelle des données, le modèle gaussien peine à capter les subtilités du territoire en comparaison aux réseaux de neurones génératifs.

Conclusion

Ce projet illustre le potentiel des réseaux de neurones génératifs pour faire face à la contrainte de rareté des données climatiques historiques, un enjeu de modélisation décisif pour le secteur de l'assurance. Les résultats de notre étude démontrent l'intérêt du conditionnement par le mois et l'année dans la génération de cartes de températures, notamment pour la modélisation d'événements extrêmes dans des scénarios précis.

L'évaluation rigoureuse de ces architectures a mis en évidence la supériorité de l'apprentissage profond par rapport aux méthodes statistiques traditionnelles pour la génération de cartes de températures. Si le modèle gaussien de référence constitue une base solide, il peine à reproduire efficacement les anomalies locales et sa performance est favorisée par la structure gaussienne conditionnelle des données. De son côté, l'algorithme KDE-PCA est incapable d'extrapoler les températures au-delà des maxima observés, ce qui limite grandement sa pertinence dans un contexte de réchauffement climatique.

À l'inverse, les modèles génératifs profonds ont prouvé leur capacité non seulement à reproduire fidèlement la dynamique spatio-temporelle existante, mais également à générer des scénarios futurs en généralisant la tendance du réchauffement climatique.

Parmi les architectures étudiées, le CVAE s'est distingué comme le modèle le plus robuste et le plus performant. Il offre la meilleure fidélité de génération, quantifiée par la *Sliced Wasserstein Distance*, ainsi que des distributions d'extrêmes parfaitement calibrées, malgré un léger lissage spatial. Le réseau cWGAN-GP est une alternative intéressante pour générer des micro-contrastes géographiques plus nets, mais il surestime la variance spatiale et l'intensité des températures maximales en raison du bruit inhérent à l'architecture GAN.

Les capacités d'extrapolation et d'enrichissement de données offertes par le réseau CVAE ouvrent donc des perspectives concrètes pour la modélisation des risques climatiques. Pour prolonger cette étude, il serait pertinent d'étendre la génération à des variables météorologiques aux distributions plus complexes, comme les précipitations extrêmes ou l'humidité des sols. Enfin, l'exploration des modèles de diffusion spatiaux pourrait constituer une suite logique à ces travaux.

Annexes

Architectures

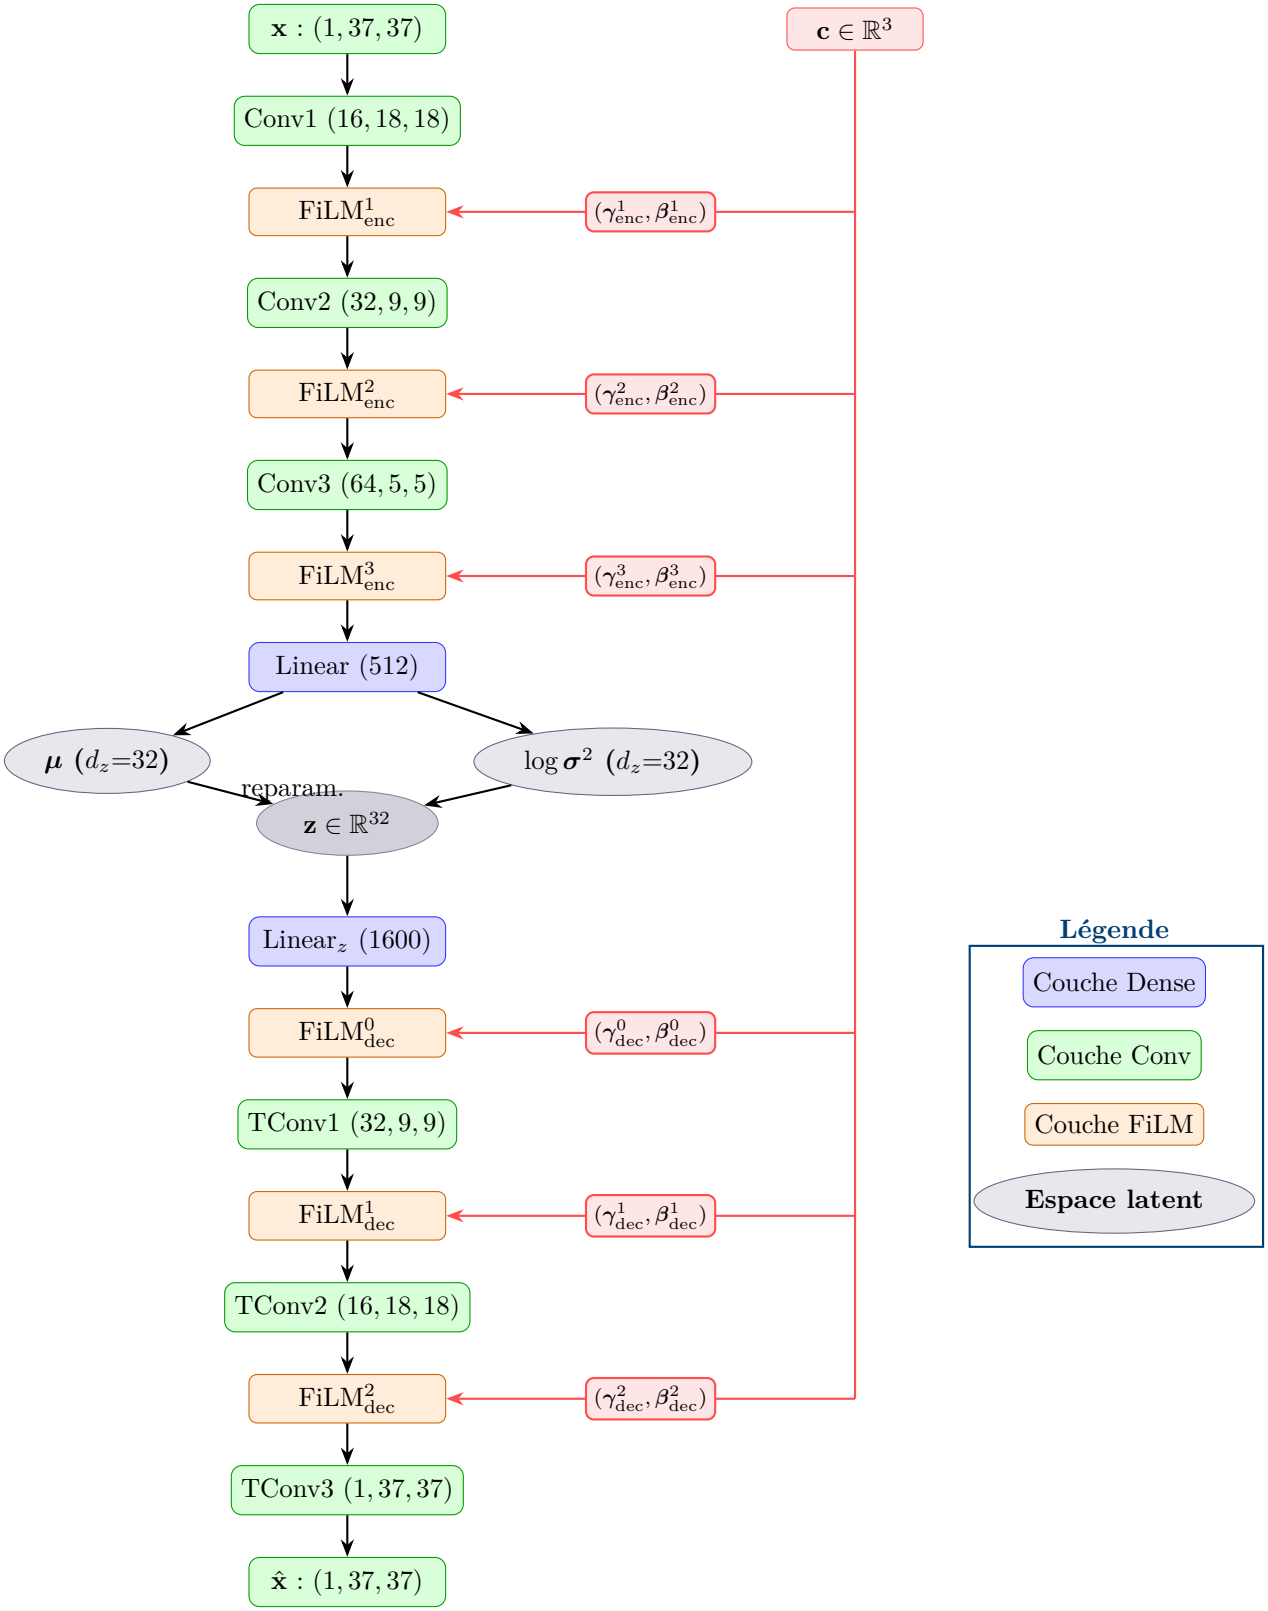

Figure 2 – Architecture du CVAE conditionnel. Le vecteur de condition $\mathbf{c}$ est projeté dynamiquement pour générer les paramètres de modulation $(\boldsymbol{\gamma}, \boldsymbol{\beta})$ propres à chaque couche FiLM de l'encodeur et du décodeur.

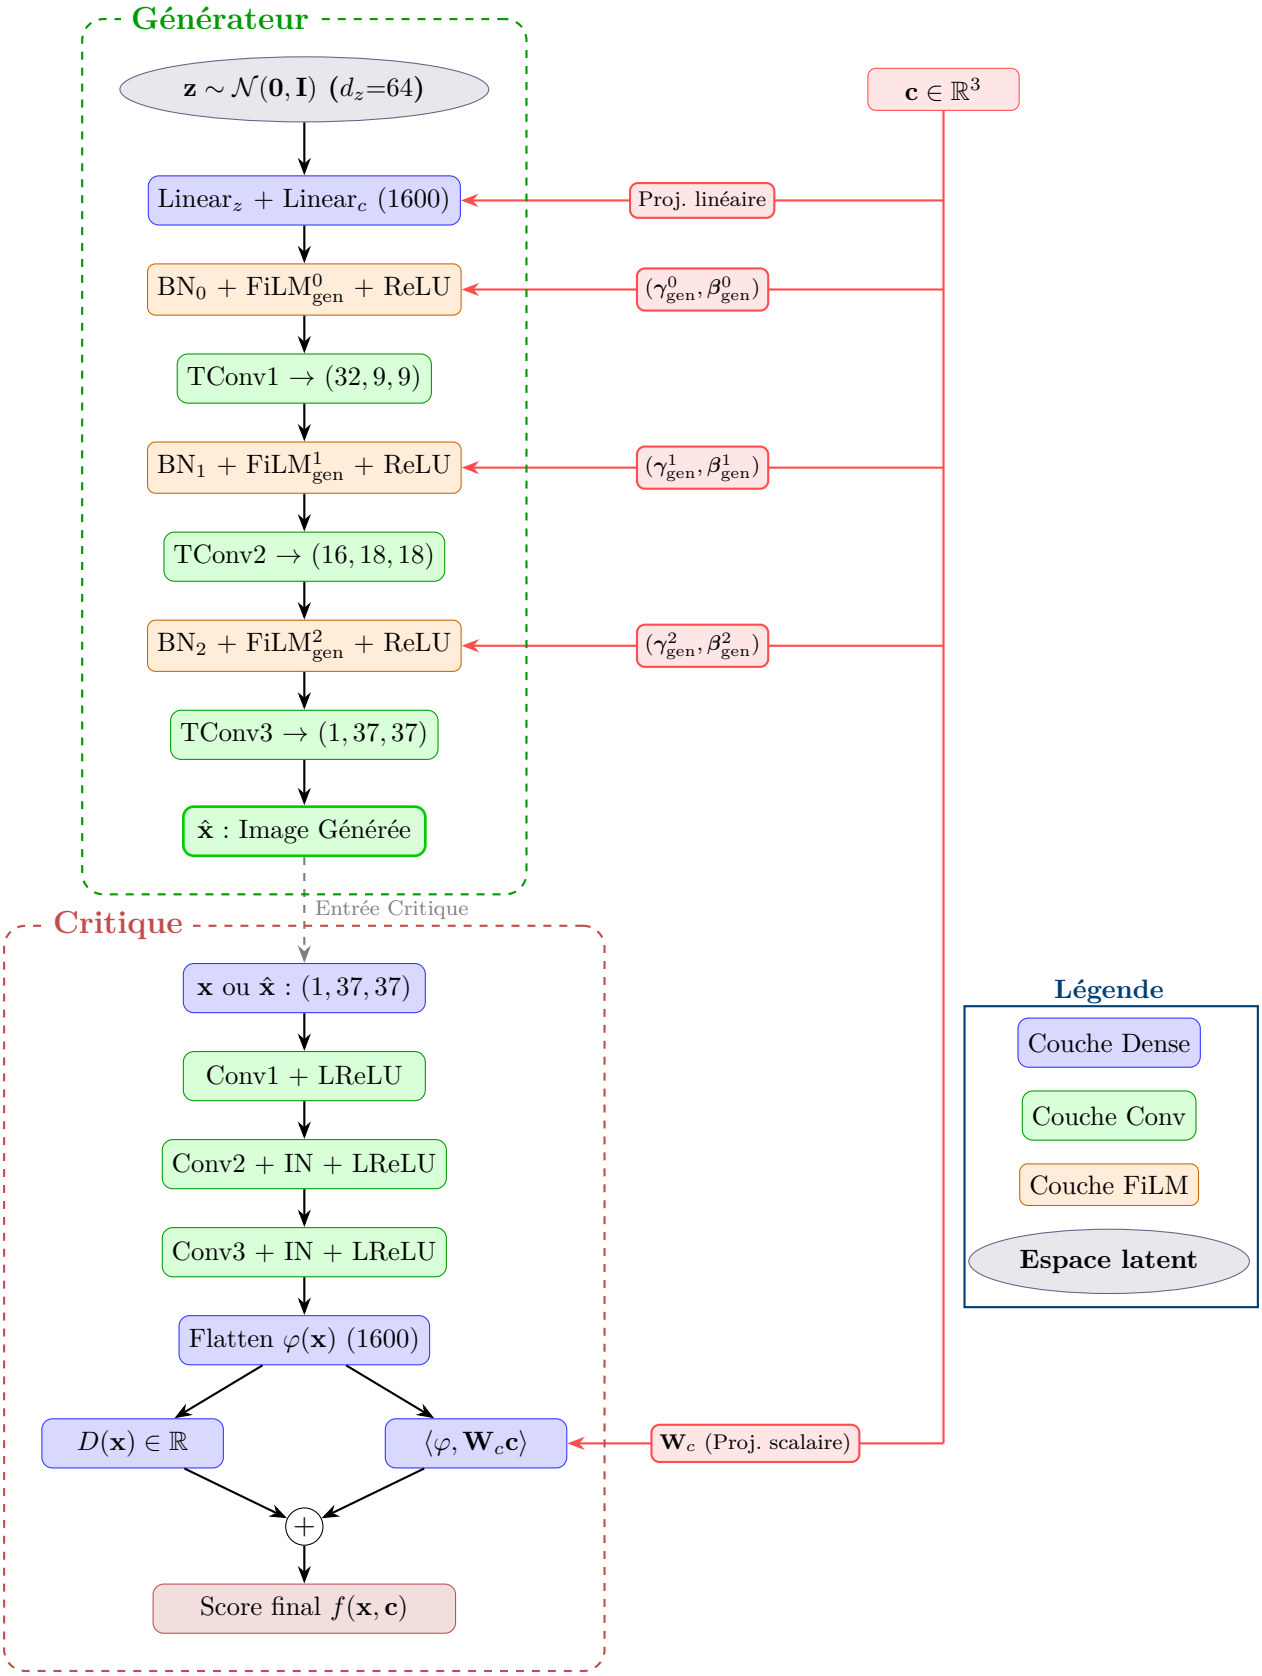

Figure 3 – Architecture du cWGAN-GP verticalisé. Les cadres délimitent le Générateur (en haut) et le Critique (en bas). La condition $\mathbf{c}$ est distribuée via un bus vertical unique alimentant la concaténation et les modulations FiLM du générateur ainsi que la projection conditionnelle du critique.

Graphiques

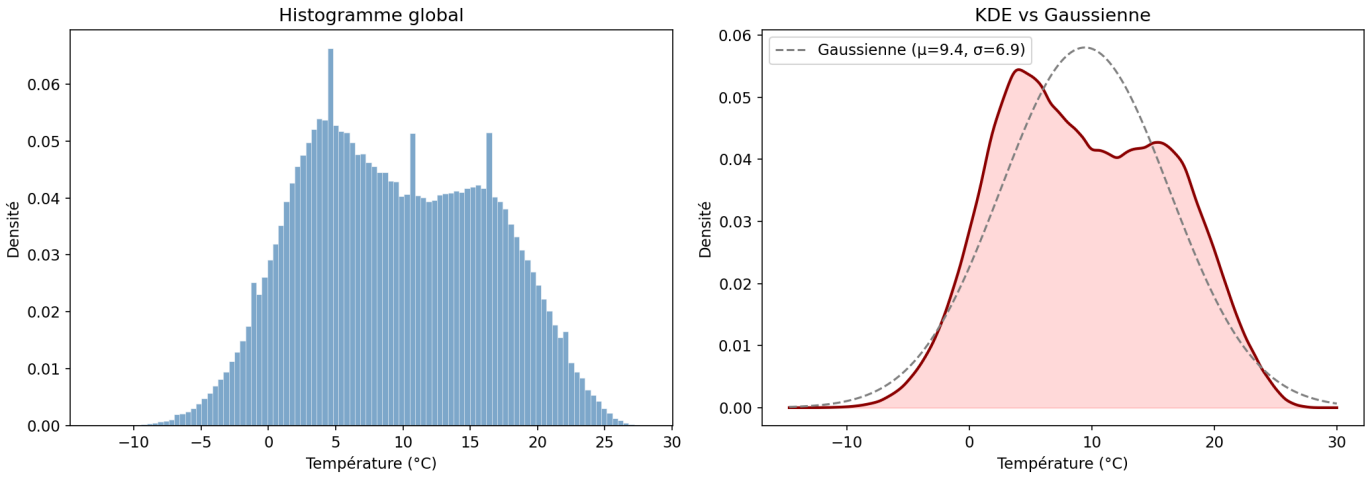

Figure 4 – Distribution de l'ensemble des données

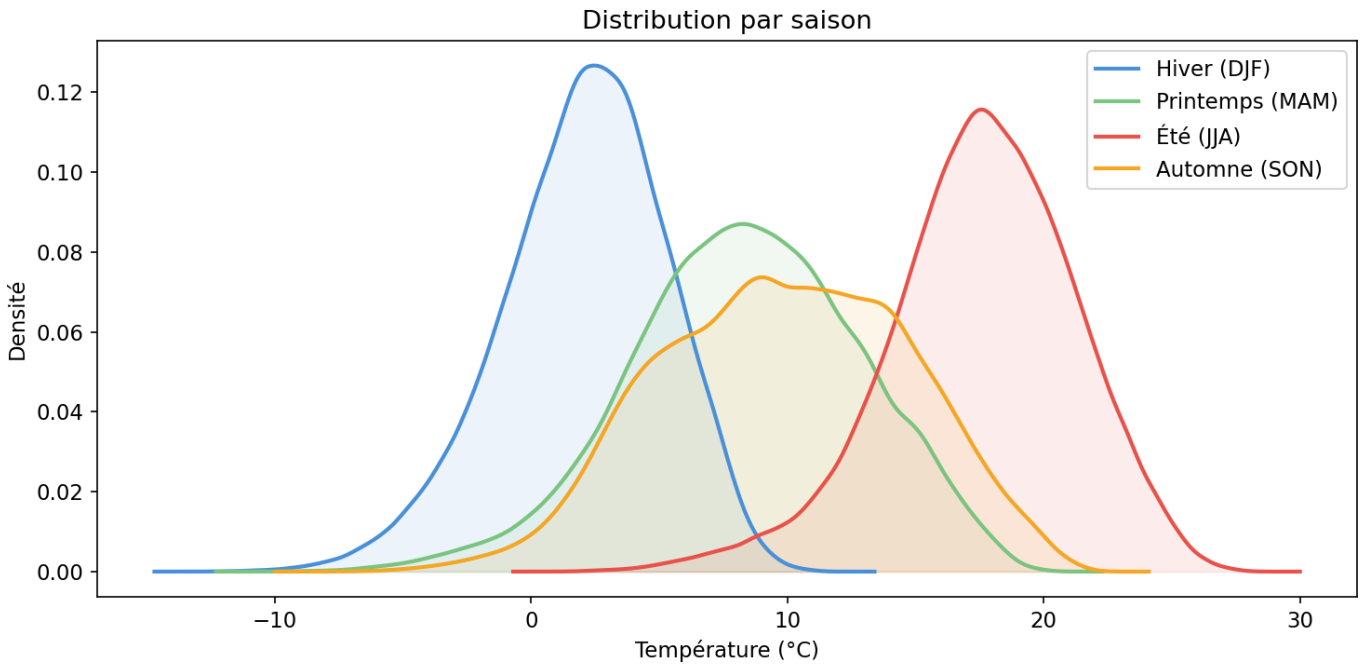

Figure 5 – Distribution des données par saison

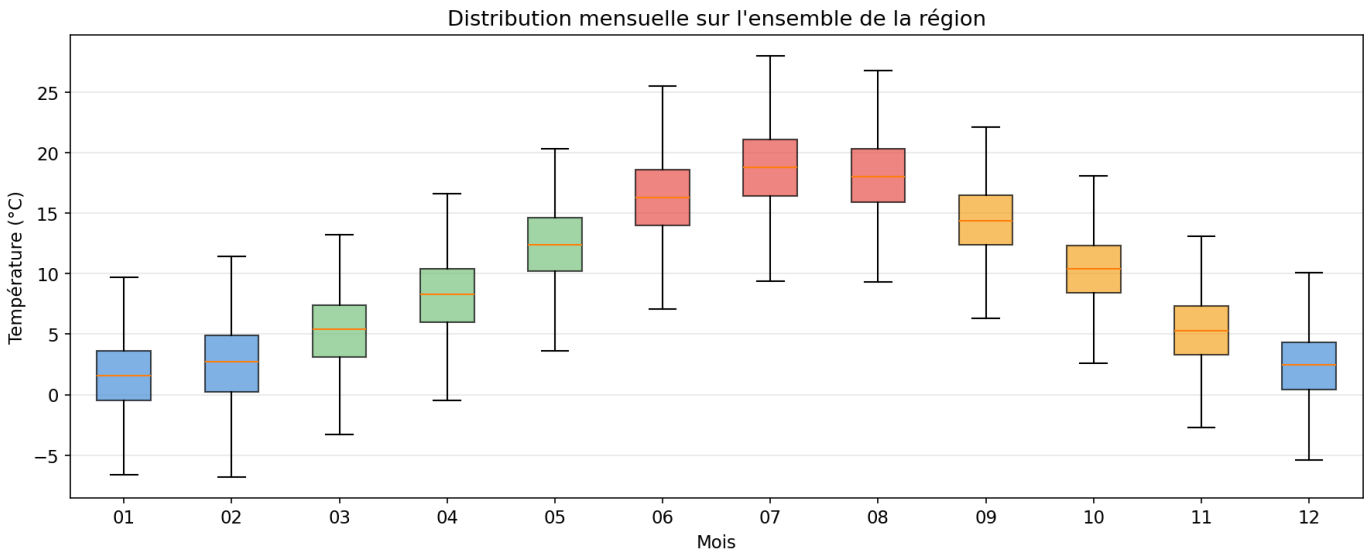

Figure 6 – Box plot des températures par mois

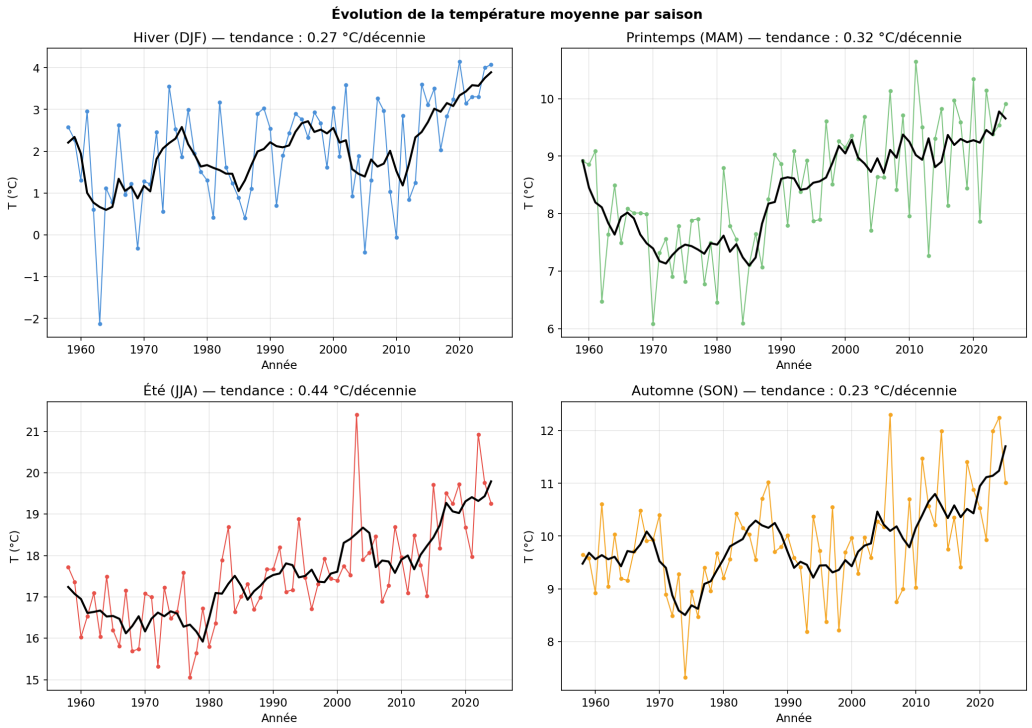

Figure 7 – Evolution de la température moyenne par saison

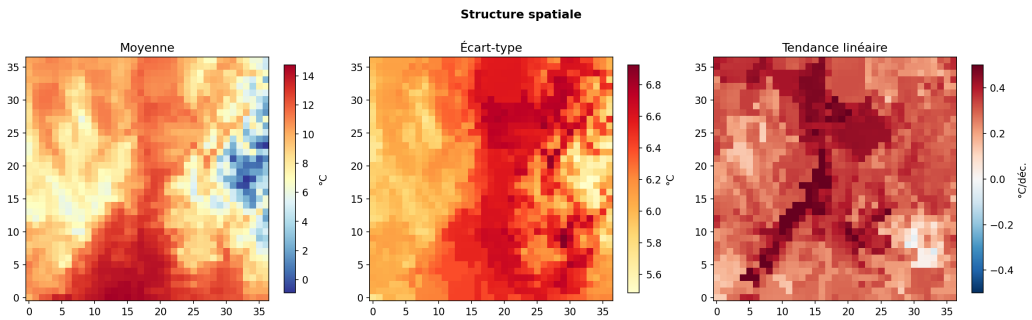

Figure 8 – Structure spatiale de la région Sud-Est

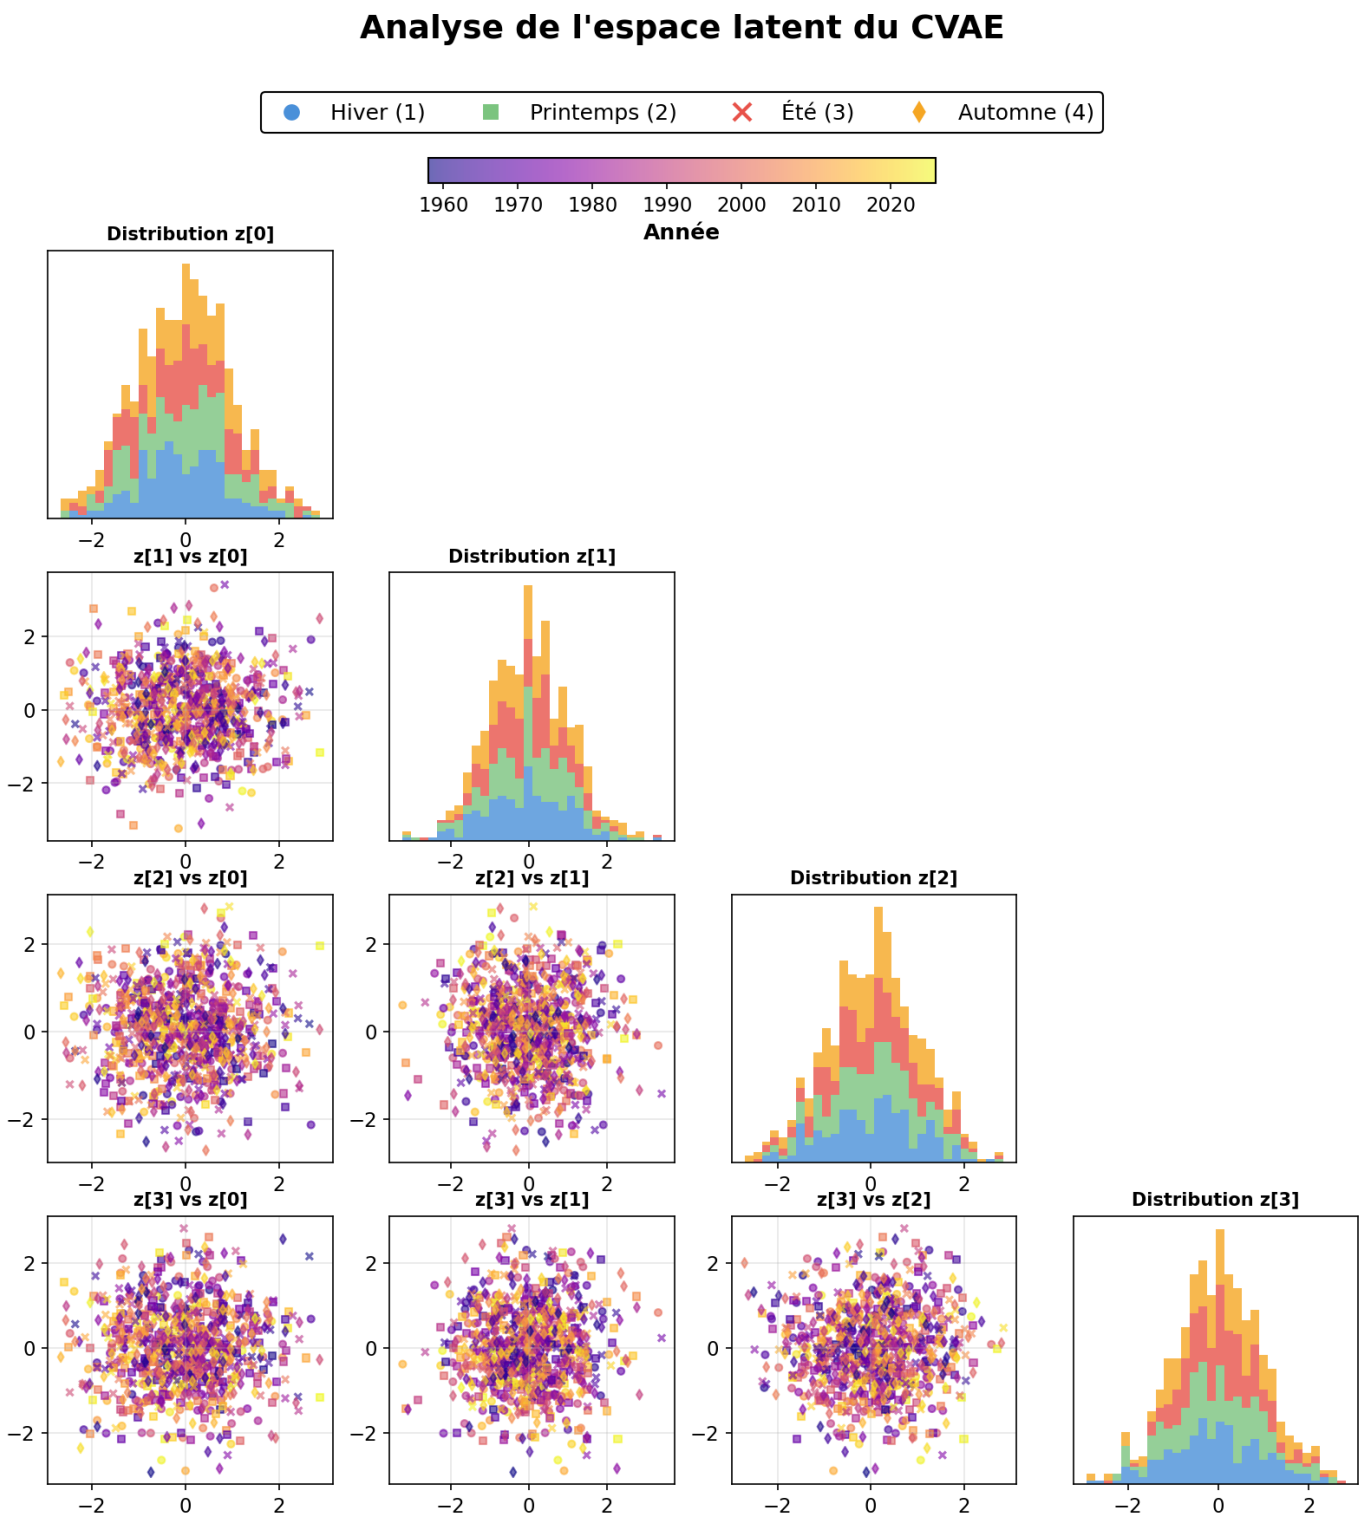

Figure 9 – Visualisation de l'espace latent du CVAE

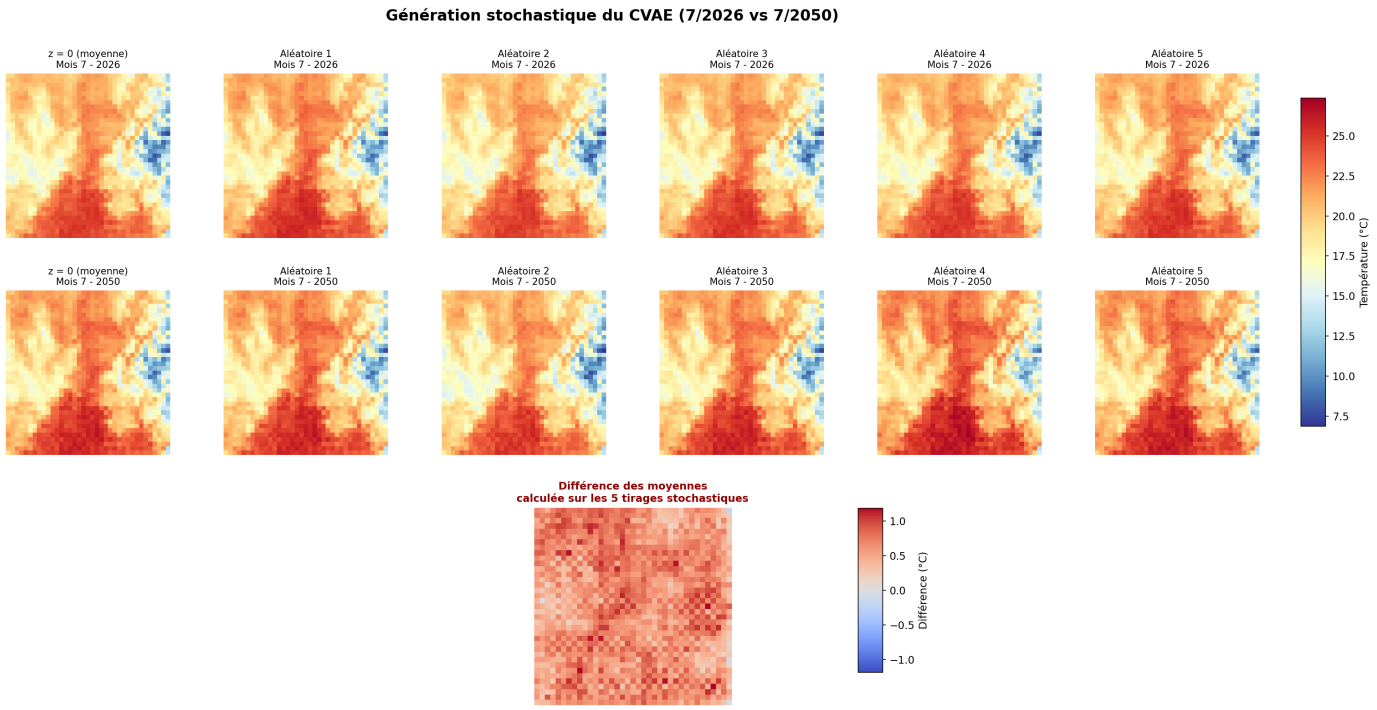

Figure 10 – Génération stochastique du CVAE pour juillet 2026 et juillet 2050

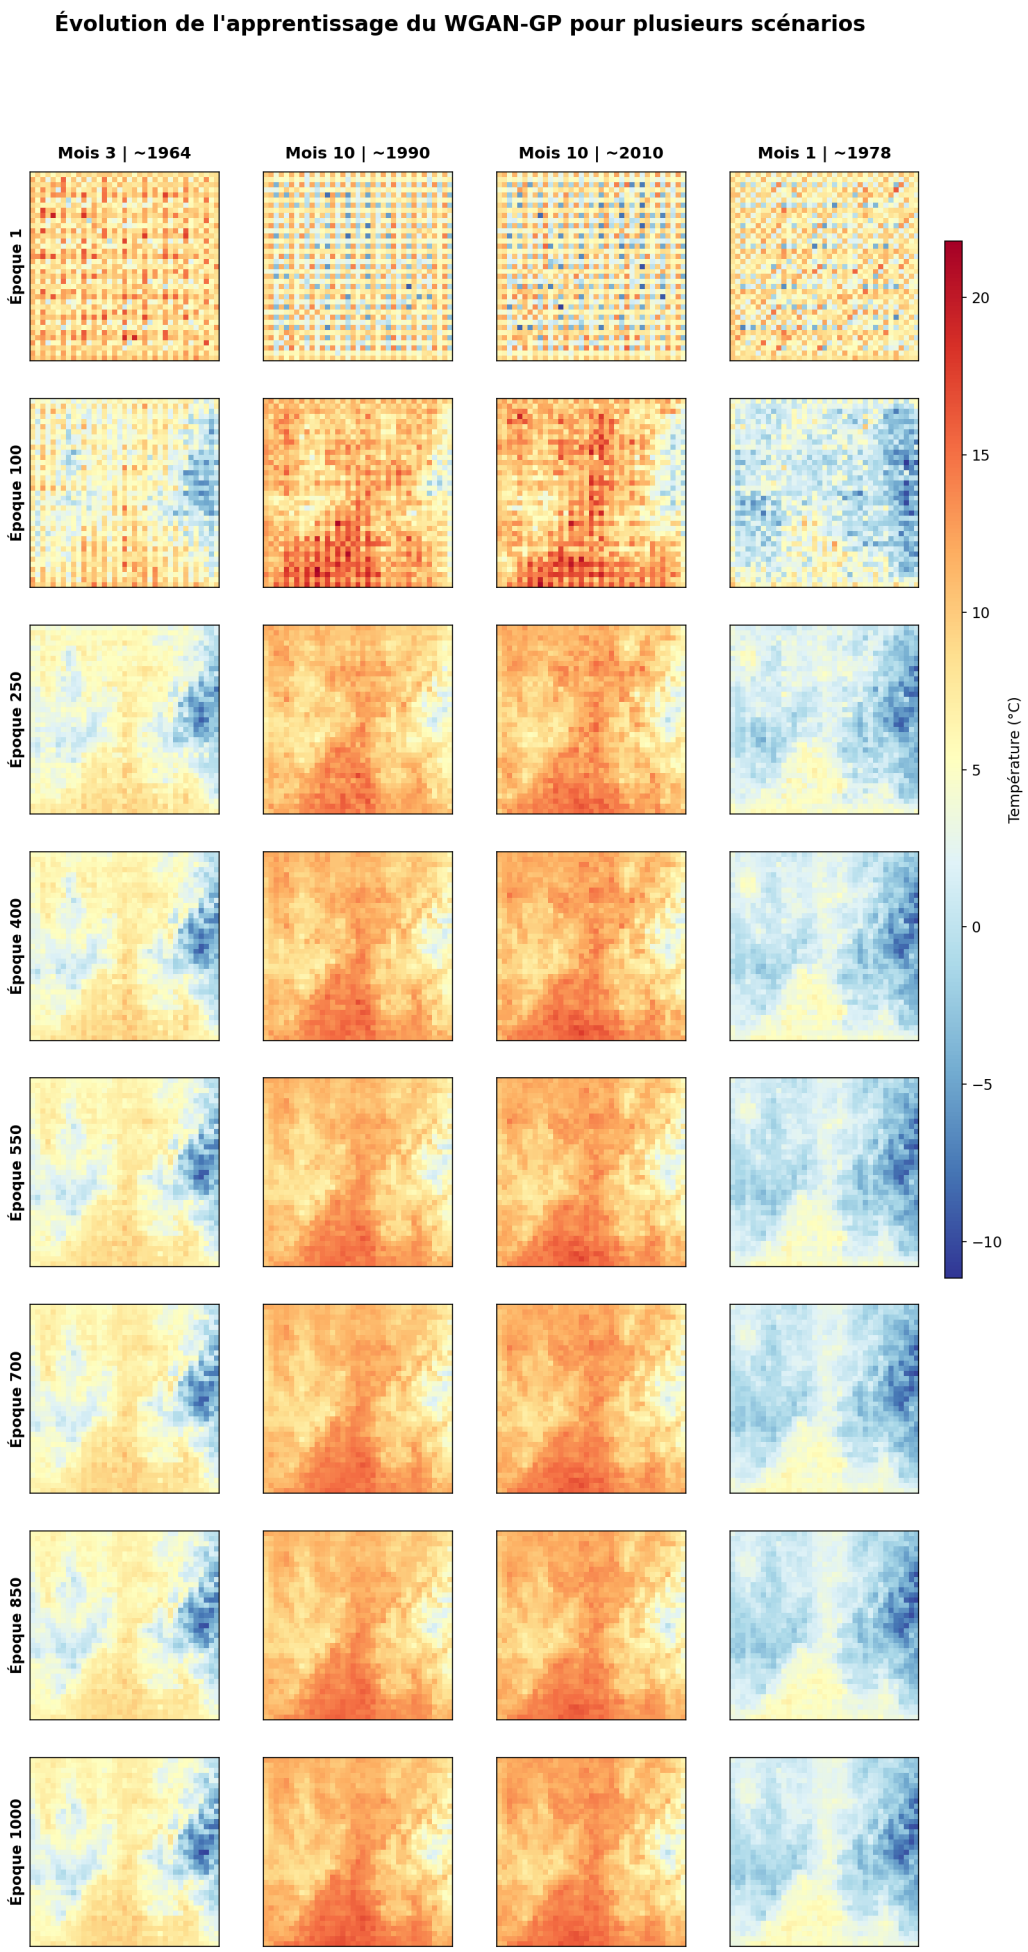

Figure 11 – Évolution de l'apprentissage du WGAN-GP

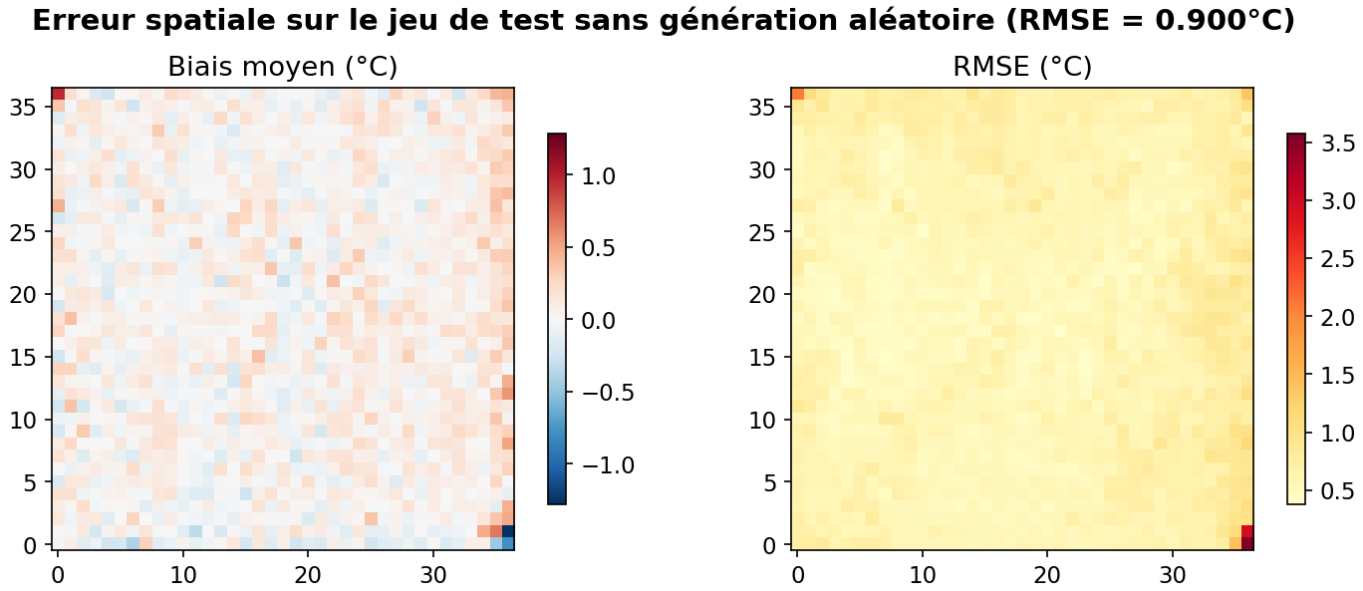

Figure 12 – Dynamique spatiale de l'erreur du CVAE

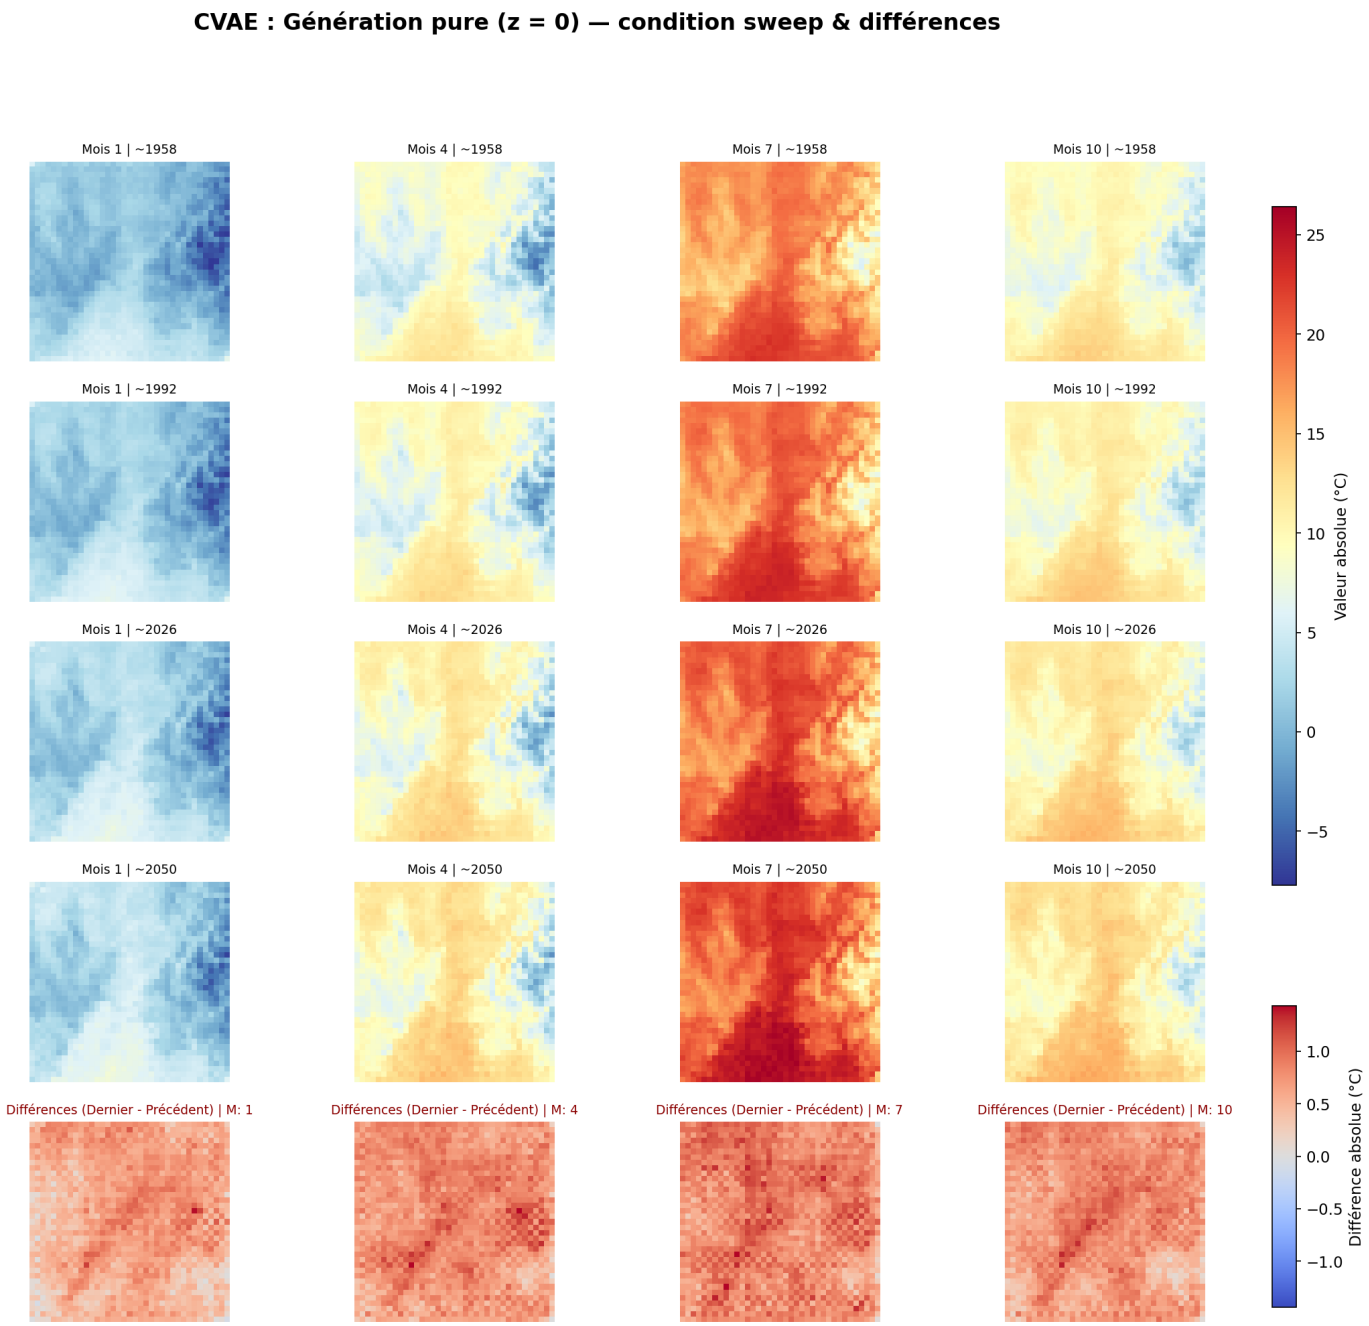

Figure 13 – Balayage de conditions avec le CVAE

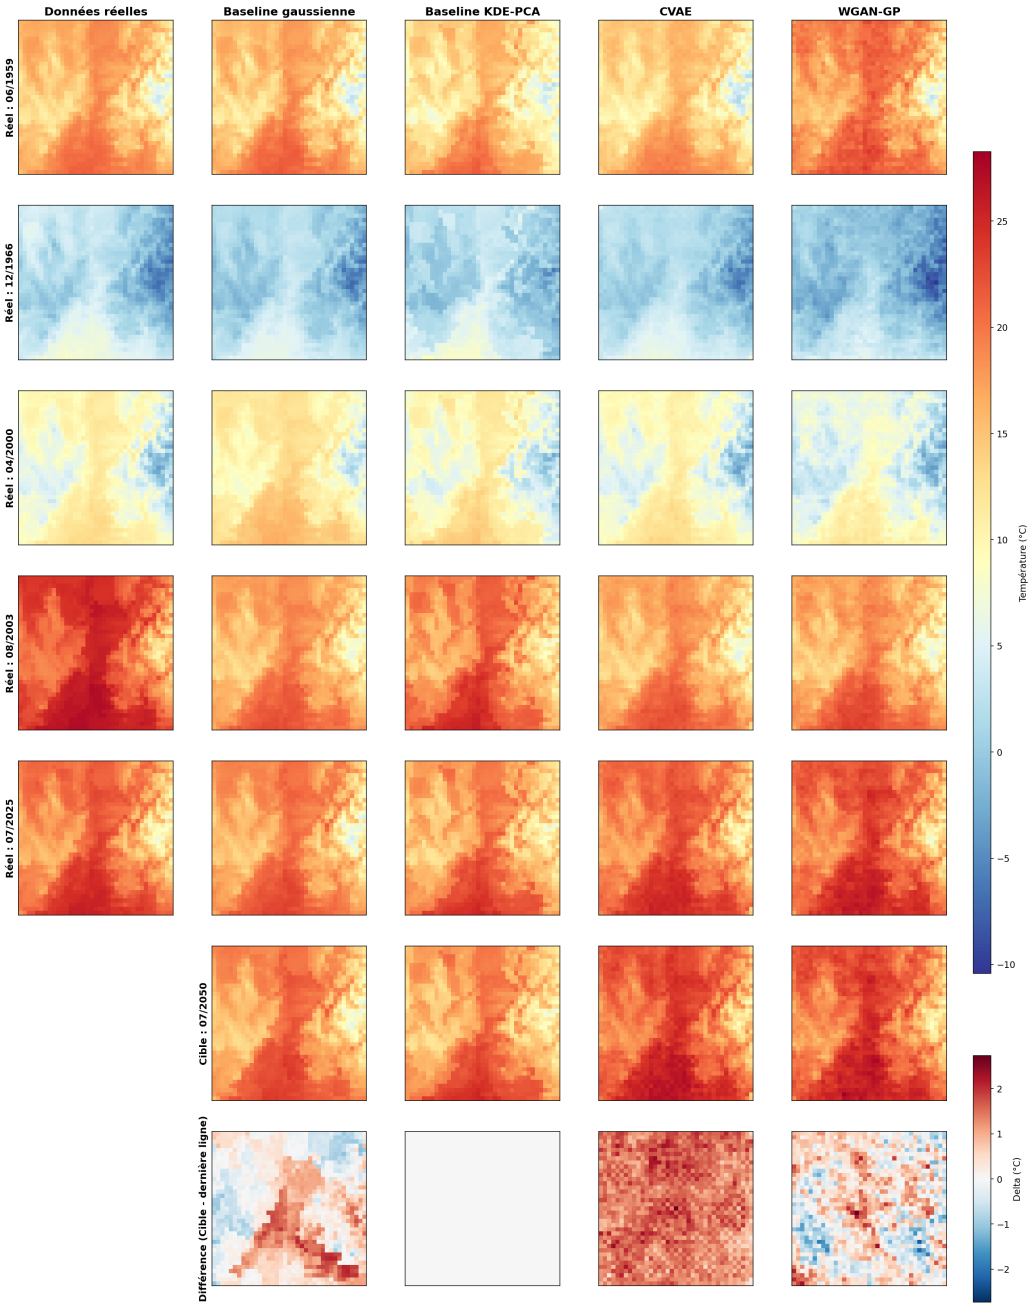

Figure 14 – Comparaison visuelle des générations pour les 4 modèles

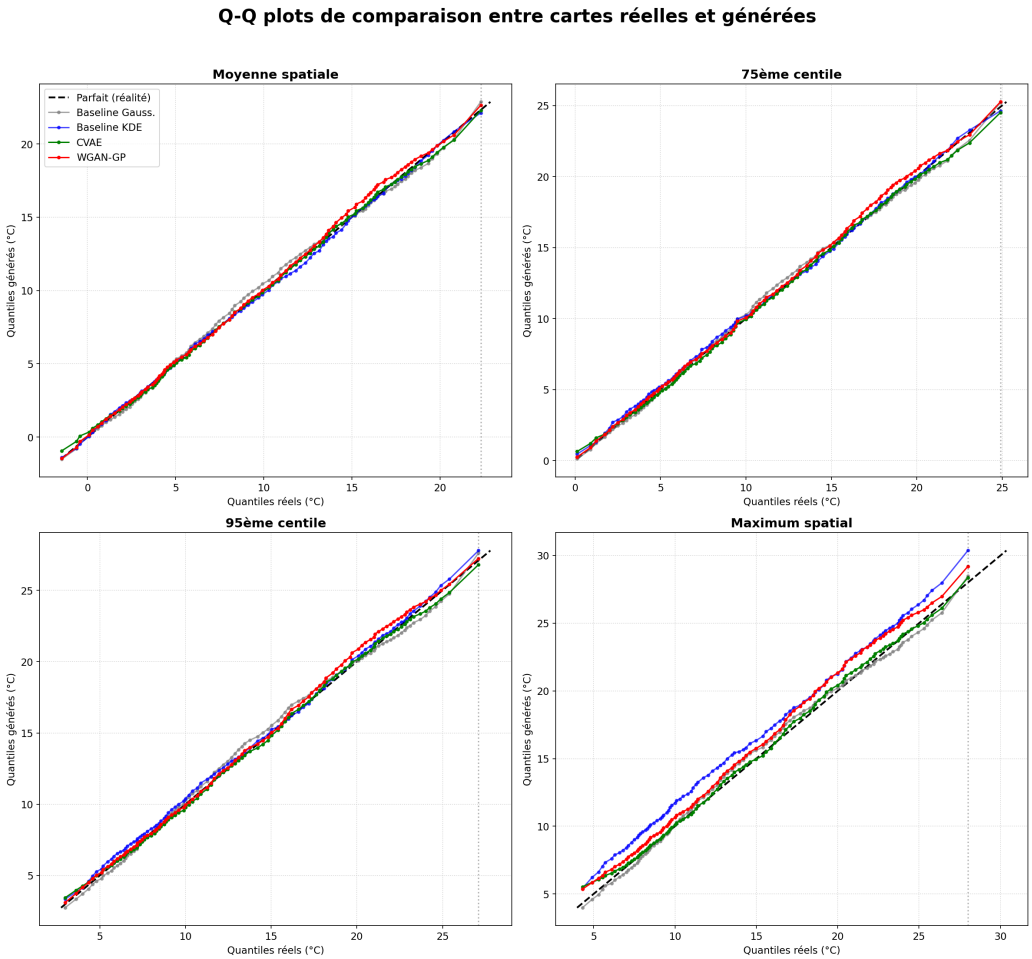

Figure 15 – Q-Q plots des générations et des cartes réelles pour les 4 modèles

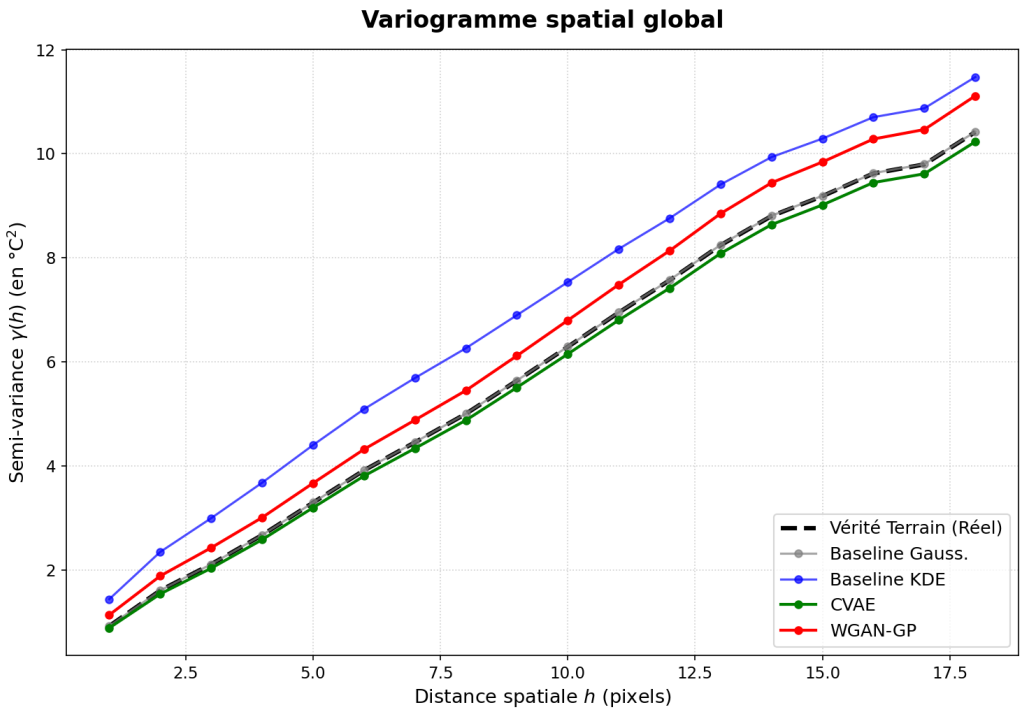

Figure 16 – Variogrammes des 4 modèles et des données réelles

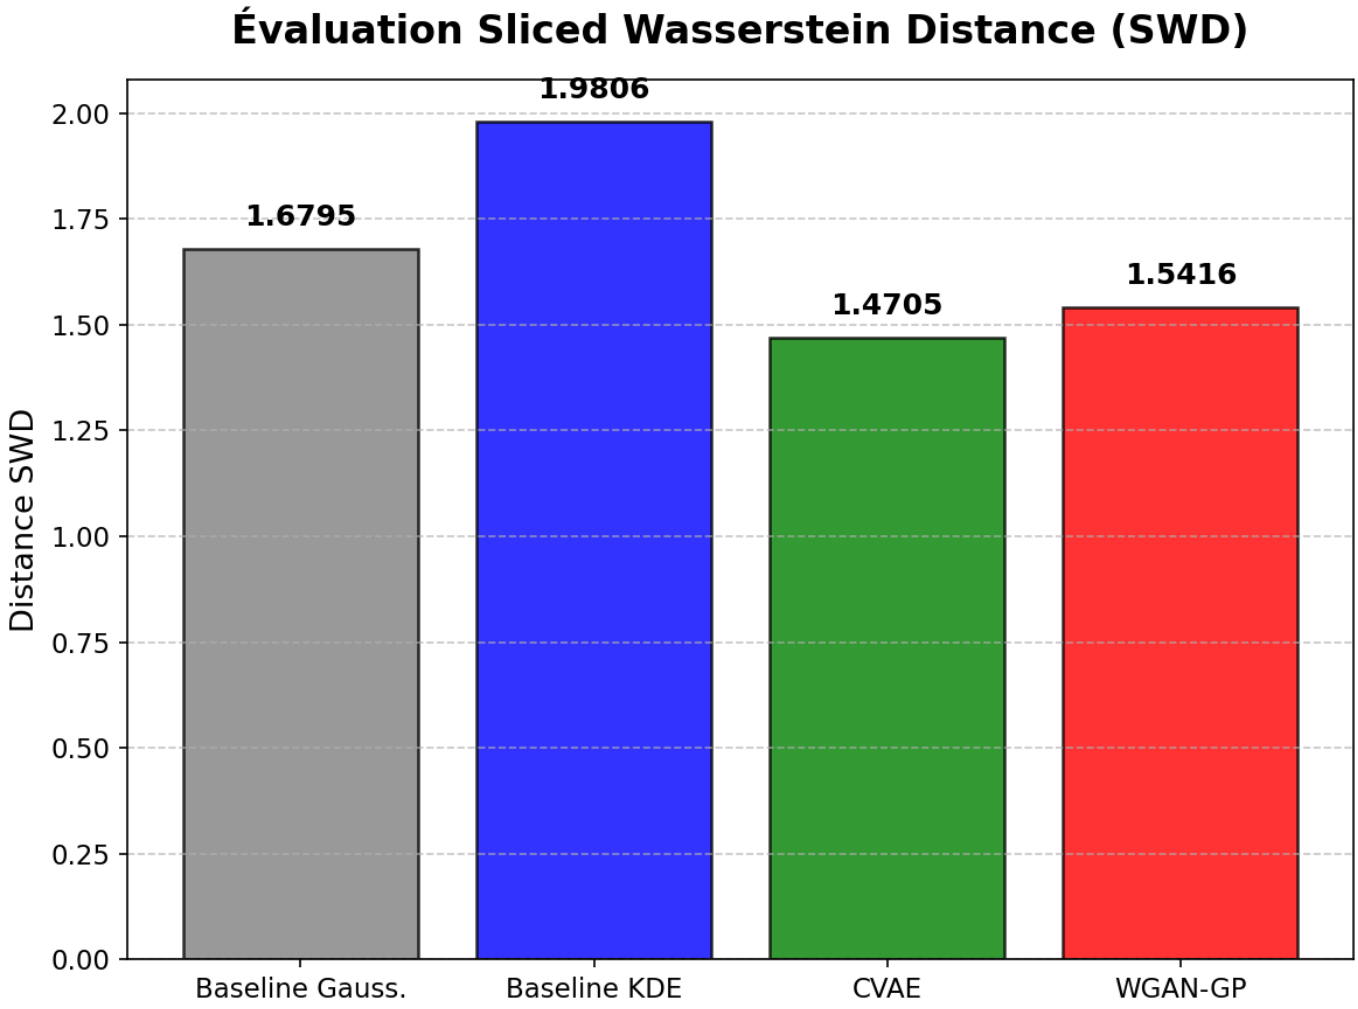

Figure 17 – Valeur de la Sliced Wasserstein Distance pour les 4 modèles

Tables

Propriété	**Valeur**
Variable cible	Température moyenne mensuelle (°C)
Résolution spatiale	8 km × 8 km (grille Lambert-II étendu)
Résolution temporelle	Mensuelle
Période couverte	Août 1958 – Mars 2026 (812 pas de temps)
Zone d'étude	Sud-Est France : LAMBX ∈ [6500, 9400], LAMBY ∈ [18500, 21500]
Taille de la grille extraite	37 × 37 pixels = 1 369 points de grille
Format source	Fichiers CSV compressés ('.csv.gz') par période

Table 1 – Caractéristiques de la base SAFRAN utilisée

Moyenne	$9,44$ °C	Médiane	$9,00$ °C
Écart-type	$6,88$ °C	Minimum	$-12,70$ °C
Q5	$-1,10$ °C	Q95	$20,70$ °C
Skewness	$0,09$	Kurtosis (excès)	$-0,82$

Table 2 – Statistiques descriptives globales (Température SAFRAN)

Dimension latente	32	Batch size	32
β^*	0,5	Epoch max	500
Durée de recuit de β	50 Epoch	Early stopping	patience 50
Optimiseur	Adam, lr=10^{-3}	LR decay	×0,5 si plateau

Table 3 – Hyperparamètres du CVAE

Couche	**Entrée**	**Sortie**	**Paramètres**
Conv2d_1 (k=3,s=2,p=0)	$(1, 37, 37)$	$(16, 18, 18)$	160
$\text{FiLM}_{\text{enc1}}$ (γ,β)	$(16, 18, 18)$	$(16, 18, 18)$	$2 \times 16 \times 3 = 96$
Conv2d_2 (k=4,s=2,p=1)	$(16, 18, 18)$	$(32, 9, 9)$	8 224
$\text{FiLM}_{\text{enc2}}$	$(32, 9, 9)$	$(32, 9, 9)$	$2 \times 32 \times 3 = 192$
Conv2d_3 (k=3,s=2,p=1)	$(32, 9, 9)$	$(64, 5, 5)$	18 496
$\text{FiLM}_{\text{enc3}}$	$(64, 5, 5)$	$(64, 5, 5)$	$2 \times 64 \times 3 = 384$
Flatten	$(64, 5, 5)$	1 600	—
Linear + ReLU	1 600	512	819 712
Linear ($\boldsymbol{\mu}$)	512	32	16 416
Linear ($\log \boldsymbol{\sigma}^2$)	512	32	16 416

Table 4 – Encodeur du CVAE : forme des tenseurs et paramètres

Dimension latente	64	Batch size	32
N_{critic}	5	Époques max	1000
λ_{GP}	10	$\text{lr}_G = \text{lr}_D$	10^{-4}
Bêtas Adam	(0,0, 0,9)	Architecture critique	ConvNet + Instance Norm

Table 5 – Hyperparamètres du WGAN-GP conditionnel

Formulations Mathématiques

Formulation mathématique de la Gradient Penalty

Soit $\hat{\mathbf{x}} = \alpha\mathbf{x} + (1-\alpha)\tilde{\mathbf{x}}$, avec $\alpha \sim \mathcal{U}[0,1]$.
La Gradient Penalty est :

$$\mathcal{L}_{\text{GP}} = \lambda \cdot \mathbb{E}_{\hat{\mathbf{x}},\mathbf{c}}\Big[\big(\|\nabla_{\hat{\mathbf{x}}} f(\hat{\mathbf{x}},\mathbf{c})\|_2 - 1\big)^2\Big] \tag{10}$$

avec λ le coefficient de pénalité, généralement égal à 10. Le gradient est calculé par différentiation automatique (`torch.autograd.grad`) avec `create_graph=True` pour permettre la rétropropagation à travers la pénalité. La norme L2 est calculée en aplatissant le gradient sur toutes les dimensions spatiales.